

新人課題

津嶋 佑旗

2019 年 4 月 17 日

1 配列情報処理

1.1 ヒト 21 番染色体の先頭コンティグの DNA 配列を秋山研サーバから取得し、A/T/G/C の各塩基数を出力せよ。

以下のように実行する。実行環境は Python2 で、ghostgw 上での動作を確認している。

```
1 python 1_1.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta
```

ソースコード 1 実行方法

プログラム本体は以下の通りである。

```
1 #2019/04/11
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4 #For Python 2.7
5
6 import sys
7
8 #file open
9 args = sys.argv
10 if len(args) != 2:
11     sys.stderr.write('Usage: python 1_1.py /NT_113952.1.fasta\n')
12     sys.exit()
13 path = args[1]
14 try:
15     file = open(path)
16 except:
17     sys.stderr.write('Error in opening file.\n')
18     sys.exit()
19 lines = file.readlines()
20 length = len(lines)
21
22 #counter(num of A/T/G/C)
23 noA = 0
24 noT = 0
25 noG = 0
26 noC = 0
27 #Process with each line
28 #Skip Header
29 for l in range(1, length):
30     noA = noA + lines[l].count('A')
31     noT = noT + lines[l].count('T')
32     noG = noG + lines[l].count('G')
33     noC = noC + lines[l].count('C')
34 print("A:" + str(noA))
35 print("T:" + str(noT))
36 print("G:" + str(noG))
37 print("C:" + str(noC))
38 file.close()
```

ソースコード 2 1_1.py

実行した結果が以下の通りである。

```
1 A:59200
2 T:56195
3 G:34714
4 C:34246
```

ソースコード 3 実行結果

1.2 NT_113952.1.fasta の逆相補鎖を生成するプログラムを作成せよ.

以下のように実行する. 実行環境は Python2 で, ghostgw 上での動作を確認している.

```
1 python 1_2.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta
```

ソースコード 4 実行方法

プログラム本体は以下の通りである.

```
1 #2019/04/05
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4 #For Python 2.7
5
6 import sys
7 from rev import rev
8 from combine import combine
9
10 #file open
11 args = sys.argv
12 if len(args) != 2:
13     sys.stderr.write('Usage: python 1_2.py ./NT_113952.1.fasta\n')
14     sys.exit()
15 path = args[1]
16 try:
17     file = open(path)
18 except:
19     sys.stderr.write('Error in opening file.\n')
20     sys.exit()
21 lines = file.readlines()
22
23 #Skip Header
24 lines.pop(0)
25 text = combine(lines)
26 #Reverse
27 reverse = rev(text)
28 print(reverse)
29
30 file.close()
```

ソースコード 5 1_2.py

```
1 #2019/04/05
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4
5 def rev(text):
6     ans = ''
7     for char in text:
8         if char == 'A':
9             ans = 'T' + ans
10        elif char == 'T':
11            ans = 'A' + ans
12        elif char == 'G':
13            ans = 'C' + ans
14        elif char == 'C':
15            ans = 'G' + ans
16    return ans
```

ソースコード 6 rev.py

```
1 #2019/04/05
2 #Yuki Tsushima
```

```

3 #tsushima@bi.c.titech.ac.jp
4
5 def combine(file):
6     ans = ''
7     for line in file:
8         ans = ans + line.strip()
9     return ans

```

ソースコード 7 combine.py

実行結果は別添する。

1.3 ウィンドウ幅 w , ステップ幅 s で、ウィンドウ内の GC 含量を出力するプログラムを作成し、NT_113952.1.fasta に $w = 1000$, $s = 300$ で適用した結果を gnuplot 等 Excel 以外のツールでプロットせよ。

以下のように実行する。実行環境は Python2 で、ghostgw 上での動作を確認している。

```

1 python 1_3.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta 1000 300 > data.txt

```

ソースコード 8 実行方法

プログラム本体は以下の通りである。また、7 も使用する。

```

1 #2019/04/11
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4 #For Python 2.7
5
6 import sys
7 from combine import combine
8
9 #file open
10 args = sys.argv
11 if len(args) != 4:
12     sys.stderr.write('Usage: python 1_3.py ./NT_113952.1.fasta 1000 300\n')
13     sys.exit()
14 path = args[1]
15 try:
16     file = open(path)
17 except:
18     sys.stderr.write('Error in opening file.\n')
19     sys.exit()
20 lines = file.readlines()
21
22 #Skip Header
23 lines.pop(0)
24 text = combine(lines)
25 length = len(text)
26
27 try:
28     w = int(args[2])
29     s = int(args[3])
30 except ValueError as e:
31     sys.stderr.write('Incorrect w or s in command line args\n')
32     sys.exit()
33
34 GC = []
35 bottom = 0
36 while bottom < length:
37     part = text[bottom:bottom+w]
38     if len(part) == 0:
39         break
40     GC.append((part.count('C') + part.count('G'))/float(len(part)))
41     bottom = bottom + s
42 #Export for gnuplot
43 for i in range(len(GC)):
44     print(str(i*300)+'_'+str(GC[i]))
45
46 file.close()

```

ソースコード 9 1_3.py

実行結果を gnuplot で描画した結果以下ようになった。

図 1 グラフ

1.4 引数で与えられた部分配列を検索し、何文字目に現れたかを表示するプログラムを作成せよ (逆相補鎖上も検索すること)。部分配列を GAATTC および ATG とし、NT_113952.1.fasta に適用せよ。

以下のように実行する。実行環境は Python2 で、ghostgw 上での動作を確認している。

```
1 python 1_4.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta GAATTC
2 python 1_4.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta ATG
```

ソースコード 10 実行方法

プログラム本体は以下の通りである。また、6 と 7 も使用する。

```
1 #2019/04/11
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4 #For Python 2.7
5
6 import sys
7 from combine import combine
8 from rev import rev
9 from findall import findall
10
11 #file open
12 args = sys.argv
13 if len(args) != 3:
14     sys.stderr.write('Usage: python 1_4.py ./NT_113952.1.fasta GAATTC\n')
15     sys.exit()
16 path = args[1]
17 try:
18     file = open(path)
19 except:
20     sys.stderr.write('Error in opening file.\n')
21     sys.exit()
22 lines = file.readlines()
23
24 lines.pop(0)
25 text = combine(lines)
```

```

26 reverse = rev(text)
27 index1 = findall(text, args[2])
28 index2 = findall(reverse, args[2])
29 print(args[2]+'_in_STRING_is_below:')
30 print(index1)
31 print(args[2]+'_in_REVERSE_STRING_is_below:')
32 print(index2)
33 file.close()

```

ソースコード 11 1_4.py

```

1 #2019/04/08
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4
5 def findall(text, query):
6     index = []
7     data = -1
8     while True:
9         data = text.find(query, data+1)
10        if data == -1:
11            break
12        index.append(data)
13    return index

```

ソースコード 12 findall.py

実行した結果が以下の通りである。ただし、ATG の結果については極端に長いため別添する。

```

1 GAATTC in STRING is below:
2 [395, 4319, 5056, 5334, 10567, 14092, 14296, 15029, 19284, 22535, 25293, 25897, 30824, 34194,
3 34625, 37333, 56600, 57464, 58202, 60553, 65241, 66725, 79939, 80725, 82012, 86322, 92914,
4 94554, 96877, 97628, 99894, 102214, 103133, 120291, 121414, 121612, 124893, 124901, 125389,
5 151452, 151874, 156137, 158738, 166310, 175826, 177983, 180004, 182341]
6
7 GAATTC in REVERSE STRING is below:
8 [2008, 4345, 6366, 8523, 18039, 25611, 28212, 32475, 32897, 58960, 59448, 59456, 62737, 62935,
9 64058, 81216, 82135, 84455, 86721, 87472, 89795, 91435, 98027, 102337, 103624, 104410,
10 117624, 119108, 123796, 126147, 126885, 127749, 147016, 149724, 150155, 153525, 158452,
11 159056, 161814, 165065, 169320, 170053, 170257, 173782, 179015, 179293, 180030, 183954]

```

ソースコード 13 実行結果 (GAATTC)

1.5 NT_113952.1.fasta を 6 つの読み枠でアミノ酸配列に変換せよ。Stop コドンはアンダースコアで表示すること。

以下のように実行する。実行環境は Python2 で、ghostgw 上での動作を確認している。

```

1 python 1_5.py /mnt/fs/ohue/newcomer/NT_113952.1.fasta

```

ソースコード 14 実行方法

プログラム本体は以下の通りである。また、6 と 7 も使用する。

```

1 #2019/04/11
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4 #For Python 2.7
5
6 import sys
7 from combine import combine
8 from rev import rev
9 from decode import decode
10
11 #file open
12 args = sys.argv
13 if len(args) != 2:
14     sys.stderr.write('Usage: python 1_5.py ./NT_113952.1.fasta\n')
15     sys.exit()
16 path = args[1]
17 try:
18     file = open(path)

```

```

19 except:
20     sys.stderr.write('Error_in_opening_file.\n')
21     sys.exit()
22 lines = file.readlines()
23
24 lines.pop(0)
25 text = combine(lines)
26 reverse = rev(text)
27 print('PEPTIDE_1')
28 print(decode(text,0))
29 print('PEPTIDE_2')
30 print(decode(text,1))
31 print('PEPTIDE_3')
32 print(decode(text,2))
33 print('PEPTIDE_4')
34 print(decode(reverse,0))
35 print('PEPTIDE_5')
36 print(decode(reverse,1))
37 print('PEPTIDE_6')
38 print(decode(reverse,2))
39 file.close()

```

ソースコード 15 1_5.py

```

1 #2019/04/08
2 #Yuki Tsushima
3 #tsushima@bi.c.titech.ac.jp
4
5 import sys
6
7 def decode(text, offset):
8     length = len(text)
9     #if too short
10    if length < offset + 3:
11        return ''
12    peptide = ''
13    CODON = {'TTT':'Phe', 'TTC':'Phe', 'TTA':'Leu', 'TTG':'Leu',\
14             'TCT':'Ser', 'TCC':'Ser', 'TCA':'Ser', 'TCG':'Ser',\
15             'TAT':'Tyr', 'TAC':'Tyr', 'TAA':'_', 'TAG':'_',\
16             'TGT':'Cys', 'TGC':'Cys', 'TGA':'_', 'TGG':'Trp',\
17             'CTT':'Leu', 'CTC':'Leu', 'CTA':'Leu', 'CTG':'Leu',\
18             'CCT':'Pro', 'CCC':'Pro', 'CCA':'Pro', 'CCG':'Pro',\
19             'CAT':'His', 'CAC':'His', 'CAA':'Gln', 'CAG':'Gln',\
20             'CGT':'Arg', 'CGC':'Arg', 'CGA':'Arg', 'CGG':'Arg',\
21             'ATT':'Ile', 'ATC':'Ile', 'ATA':'Ile', 'ATG':'Met',\
22             'ACT':'Thr', 'ACC':'Thr', 'ACA':'Thr', 'ACG':'Thr',\
23             'AAT':'Asn', 'AAC':'Asn', 'AAA':'Lys', 'AAG':'Lys',\
24             'AGT':'Ser', 'AGC':'Ser', 'AGA':'Arg', 'AGG':'Arg',\
25             'GTT':'Val', 'GTC':'Val', 'GTA':'Val', 'GTG':'Val',\
26             'GCT':'Ala', 'GCC':'Ala', 'GCA':'Ala', 'GCG':'Ala',\
27             'GAT':'Asp', 'GAC':'Asp', 'GAA':'Glu', 'GAG':'Glu',\
28             'GGT':'Gly', 'GGC':'Gly', 'GGA':'Gly', 'GGG':'Gly'}
29
30    start = offset
31    end = start + 3
32    try:
33        #Skip to Met
34        while end <= length:
35            if CODON[text[start:end]] == 'Met':
36                break
37            start = end
38            end = start + 3
39        #Decode
40        while end <= length:
41            peptide = peptide + '_' + CODON[text[start:end]]
42            if peptide[len(peptide)-1] == '_':
43                break
44            start = end
45            end = start + 3
46        return peptide.strip()
47    except (KeyError):
48        sys.stderr.write('Unknown_CODON_Error\n')
49        return ''

```

ソースコード 16 decode.py